

Informe Final - Consultoria InmoValor S.A

Rodrigo Mansilla
Javier Chen
5 de Mayo de 2025
Ciudad de Guatemala
Repositorio:

<https://github.com/Rodrimansidub14/DM-Proyecto-2.git>

Resumen Ejecutivo

- **Objetivo de la consultoría:** Predicción del precio de viviendas y segmentación de mercado.

Metodología

A partir del conjunto de datos se modelaron modelos de regresión y clasificación para predecir el valor de las casas. A partir de cada modelo desarrollado se modificaron los parámetros que se ajustaban mejor a los datos. Posteriormente se evaluaron y se desarrollaron conclusiones sobre cada modelo.

Análisis Exploratorio de Datos.

A continuación, se presentan los hallazgos clave de la exploración inicial del conjunto de datos de propiedades, enfocados en variables numéricas y su preparación para el modelado predictivo.

Se trabajó con el siguiente conjunto de datos:

Métrica	Valor
Número de filas	1460
Número de columnas	81

1. Estadísticas Descriptivas

Variable	Media	Desviación Estándar	Rango Aprox.
SalePrice	180 921	79 443	34 900 – 755 000
GrLivArea	1 515	525	334 – 5 642
LotArea	10 517	9 981	1 300 – 215 245
X1stFlrSF	1 163	387	334 – 4 692
TotalBsmtSF	1 057	439	0 – 6 110
OverallQual	6.10	1.38	1 – 10
OverallCond	5.58	1.11	1 – 9
YearBuilt	1 971	30	1872 – 2010
YearRemodAdd	1 985	21	1950 – 2010
LotFrontage	70.05	24.28	21 – 313 (17 % NA)
MasVnrArea	103.7	181.1	0 – 1 600 (muchos 0)
GarageArea	473	214	0 – 1 418

Variable	Media	Desviación Estándar	Rango Aprox.
GarageCars	1.77	0.75	0 – 4

Variables de área (GrLivArea, LotArea, X1stFlrSF, TotalBsmtSF) muestran alta variabilidad y presencia de outliers. Calidad (OverallQual, OverallCond) y antigüedad (YearBuilt, YearRemodAdd) aportan información discreta pero relevante.

2. Distribución y Outliers

- **SalePrice:** Sesgo pronunciado a la derecha; varios outliers en la cola superior.
- **LotFrontage** y **MasVnrArea:** Alto porcentaje de ceros o NA; colas largas con pocos valores extremos.
- **GrLivArea, LotArea, X1stFlrSF, TotalBsmtSF:** Distribuciones asimétricas con valores atípicos.


3. Pruebas de Normalidad

Variable	Shapiro-Wilk p-value	Anderson-Darling p-value
SalePrice	$< 2.2 \times 10^{-16}$	0
LotArea	$< 2.2 \times 10^{-16}$	0
MasVnrArea	$< 2.2 \times 10^{-16}$	0
GrLivArea	$< 2.2 \times 10^{-16}$	0
TotalBsmtSF	$< 2.2 \times 10^{-16}$	0
OverallQual	$< 2.2 \times 10^{-16}$	0
OverallCond	$< 2.2 \times 10^{-16}$	0
YearBuilt	$< 2.2 \times 10^{-16}$	0
YearRemodAdd	$< 2.2 \times 10^{-16}$	0

Ninguna variable sigue distribución normal. Fue imprescindible aplicar transformaciones y estrategias de manejo de outliers antes del modelado.

Variables Relacionadas con la Construcción y Estructura

- **Tipo de Edificación:** Predominan las casas unifamiliares (1Fam).
- **Estilos de Vivienda:** Mayoría de estilos de 1 y 2 pisos (1Story, 2Story).
- **Techos:** Dominio de techos de tipo **Gable** y material **CompShg**.
- **Cimientos:** Principalmente de concreto (“PConc”) y madera (“Wood”).



Estos patrones ayudan a identificar las características estructurales más comunes en el parque residencial.

Variables Relacionadas con el Exterior y Materiales

- **Condición y Calidad Exterior:** La mayoría en estado promedio (TA), con pocas en estado excelente (Ex) o deficiente (Fa).
- **Revestimientos:**
 - Exterior1st y Exterior2nd dominados por **VinylSd**.
 - Le siguen **MetalSd**, **Wd Sdng** y **HdBoard**.
- **Mampostería Vista** (MasVnrType):
 - Mayoría "BrkFace", segundo "Stone".

Indica un mercado residencial con acabados estándar y revestimientos vinílicos o metálicos, y menor presencia de materiales premium.

Variables Relacionadas con el Sótano

- **Calidad (BsmtQual) y Condición (BsmtCond):** Predominantemente "TA" o "Gd", con pocos casos "Ex" o "Fa".
- **Exposición** (BsmtExposure): Principalmente "No", aunque hay grupos "Gd", "Mn" y "Av".
- **Tipo de Acabado** (BsmtFinType1 / BsmtFinType2):
 - BsmtFinType1: predominan "GLQ" y "Unf".
 - BsmtFinType2: casi todo "Unf".


Gran parte de los sótanos no están terminados o tienen acabados básicos, lo que puede limitar el espacio habitable adicional.

Variables Relacionadas con el Garaje

- **Tipo** (GarageType): Mayoría de garajes adjuntos ("Attchd"), luego separados ("Detchd") y sin garaje ("NA").
- **Acabado** (GarageFinish): Predominan los sin acabado ("Unf").

Posteriormente se desarrollaron preguntas exploratorias como:

Relación entre Variables de Área y Precio de Venta




Variables: GrLivArea, LotArea, X1stFlrSF, TotalBsmtSF

Moduladores: OverallQual, OverallCond, Neighborhood, MSZoning

- **GrLivArea vs. SalePrice**
 - Tendencia claramente positiva: a mayor área habitable, mayor precio.
 - Las casas con **OverallQual** alto (8–10) se agrupan en la parte superior de la nube, mostrando que calidad y tamaño se combinan para elevar el valor.
- **LotArea vs. SalePrice**
 - Relación positiva menos nítida: lotes muy grandes no siempre conllevan precios máximos.
 - Al colorear por **OverallCond**, se ve que casas en mejor condición ocupan rangos de precio más altos aun con lotes de tamaño similar.
- **X1stFlrSF vs. SalePrice** (por Neighborhood)
 - Creciente relación entre superficie del primer piso y precio.
 - Barrios “premium” (NoRidge, NridgHt, OldTown) muestran precios elevados incluso con X1stFlrSF moderada, mientras que barrios de menor nivel requieren más área para igualar precio.
- **TotalBsmtSF vs. SalePrice** (por MSZoning)
 - Positiva correlación entre tamaño de sótano y precio.
 - En zonas residenciales de baja densidad (RL, FV), los precios son mayores a igualdad de TotalBsmtSF que en zonas multifamiliares (RM).

Conclusión: El área habitable y de sótano impulsa el precio, pero la magnitud del efecto depende de la calidad de la vivienda y de su ubicación.

Influencia de las Características del Sótano




Variables: BsmtQual, BsmtCond, BsmtFinType1, BsmtFinSF1, BsmtFinSF2

- **Calidad y Condición (BsmtQual / BsmtCond)**
 - Boxplots muestran que sótanos con calidades “Gd”/“Ex” y condiciones “Gd” alcanzan precios medianos significativamente más altos que “TA” o “Fa”.
- **Tipo de Acabado (BsmtFinType1)**
 - Sótanos con “GLQ” o “ALQ” superan en precio a aquellos “Unf” (sin terminar).
- **Área Terminada (BsmtFinSF1 / BsmtFinSF2)**
 - Ambas series correlacionan positivamente con SalePrice, especialmente BsmtFinSF1 (acabado principal).

Conclusión: Un sótano de buena calidad y mayor área terminada agrega valor tangible al precio de venta.

Impacto de Años de Construcción y Remodelación



Variables: YearBuilt, YearRemodAdd



- **YearBuilt vs. SalePrice**
 - Dispersión positiva: casas más nuevas tienden a tener precios promedio más altos.
 - Algunos inmuebles históricos (antes de 1940) también alcanzan precios altos, probablemente por remodelaciones o ubicación privilegiada.
- **Precio por Década de Construcción**
 - Boxplots revelan un aumento gradual en la mediana del precio con cada década más reciente, aunque con solapamiento entre décadas.
- **YearRemodAdd vs. SalePrice**
 - Tendencia similar: una remodelación reciente impulsa el valor, especialmente en casas antiguas.

Conclusión: La antigüedad y el año de remodelación explican variaciones significativas en el precio, reforzando la importancia de mantener o modernizar la vivienda.


Agrupamiento

Los resultados del agrupamiento fueron constantes con los algoritmos seleccionados, no se observó una clara separación entre los grupos o estructuras marcadas en los datos.

VAT sobre muestra de 1120 observaciones



El análisis de componentes principales permitió identificar la contribucion de las variables.



Análisis de Agrupamiento y Componentes Principales

1. Componentes Principales (PCA)

- Dimensión 1 (Dim1)**
Captura la mayor parte de la varianza asociada al **valor de la casa**, integrando directamente:
 - Tamaño de la vivienda (GrLivArea, TotalBsmtSF, GarageArea)
 - Calidad global (OverallQual)
 - Precio de venta (SalePrice)
- Dimensión 2 (Dim2)**
Explica un matiz secundario relacionado con:
 - Tamaño del lote (LotArea)
 - Antigüedad de la vivienda (YearBuilt, YearRemodAdd)Su contribución a la varianza total es menor, pero permite distinguir propiedades por su contexto y edad.
- Variables correlacionadas**
Las siguientes variables presentan alta contribución y cos² en las dos primeras componentes:
 - SalePrice
 - OverallQual
 - GrLivArea
 - TotalBsmtSF
 - GarageArea

Esto refuerza que la **calidad** y los **espacios construidos** son los principales impulsores del precio.

2. Ejes Interpretables del PCA

Eje	Interpretación principal
Eje 1	Valor de venta / Calidad / Tamaño construido

Eje	Interpretación principal
Eje 2	Tamaño de lote / Año de construcción / Antigüedad

3. Resultados de Clustering (K-means)

- **Número de clusters óptimo:**
El método del codo y el índice de silueta sugieren que **k = 3** ofrece un buen equilibrio entre compacidad e interpretabilidad.
- **Descripción de los clusters:**
 1. **Cluster 1 (Alto valor):** Viviendas grandes, de alta calidad y precio elevado.
 2. **Cluster 2 (Valor medio):** Propiedades de tamaño y calidad intermedios.
 3. **Cluster 3 (Bajo valor):** Viviendas más pequeñas, calidad básica y precios más bajos.
- **Calidad de segmentación:**
 - Silhouette promedio ~ 0.23 (k=3), suficiente para diferenciar grupos sin crear sobrefragmentación.
 - Con k = 4 se mejora ligeramente la silueta (0.27), pero se complica la interpretación.


Recomendación: Adoptar k = 3 para agrupar el mercado en tres segmentos claros (mercado alto, medio y bajo), facilitando la toma de decisiones estratégicas.

Resultados del Modelado Predictivo

1. Predicción Numérica (Regresión)

1.1 Modelos Lineales

- **OLS, Stepwise, Lasso, Ridge**
 - Explican gran parte de la variabilidad del precio.
 - RMSE en test: ≈ 0.10–0.12.
- **Stepwise** y **Lasso** destacan por su equilibrio entre precisión y simplicidad, aunque presentan dificultades con valores extremos.



Predicción Modelo Stepwise


1.4 Conclusiones en Regresión

- Para **precisión pura**, **Random Forest** es el modelo más robusto.
- Los **modelos lineales** (especialmente Stepwise y Lasso) siguen siendo competitivos y ofrecen mayor interpretabilidad.
- El **árbol individual** es menos preciso, pero facilita la comprensión de las reglas de predicción.

2. Clasificación (Económicas, Intermedias, Caras)

2.1 Árbol Base


- Exactitud en test: 70 %–72 %.
- Errores frecuentes entre las clases “Económicas” e “Intermedias”.



2.2 Árbol Ajustado con Validación Cruzada

- Mejora la exactitud hasta ~ 75 %–78 % gracias al ajuste de hiperparámetros.

- Mantiene buena interpretabilidad y equilibrio entre clases.



2.3 Random Forest (Clasificación)

- Puede alcanzar una exactitud de 80 %–85 % (o superior), a costa de menor transparencia.
- Modelos muy profundos tienden a **sobreajustar** (100 % en entrenamiento) sin siempre traducir esa mejora a test.

2.4 Conclusión en Clasificación


- Un **árbol ajustado** logra un buen balance entre precisión (~ 75 %–78 %) e interpretabilidad.
- **Random Forest** maximiza la exactitud cuando la claridad interpretativa no es prioritaria.

3. Naive Bayes.


3.1 Resultados – Regresión

- Métricas de desempeño

- $RMSE = 0.2316$, $MAE = 0.1644$, $MAPE = 1.367\%$, $R^2 = 0.6953$.



- Gráfico “Valores reales vs. predicción” muestra nube dispersa alrededor de la diagonal, con mayor error en extremos.



3.2 Naive Bayes para clasificación (PriceCat)

- Creación de categorías

- Económicas (< 11.80904), Intermedias [11.80904, 12.29739), Caras $\geq$ 12.29739 .
- **Distribución**
 - Train: Económicas 275, Intermedias 548, Caras 275.
 - Test: Económicas 71, Intermedias 131, Caras 65 NaiveBayes

Métricas globales

Conjunto	Accuracy	Kappa
Entrenamiento	0.6721	0.5251
Prueba	0.6292	0.4633

- **Brecha moderada** (< 5 pp) indica cierto sobreajuste ligero pero aceptable.

Métricas por clase (prueba)

Clase	Sensibilidad	Especificidad	Precisión	F1	Balanced Acc.
Económicas	0.9718	0.7908	0.6273	0.7624	0.8813
Intermedias	0.3588	0.8971	0.7705	0.4896	0.6279
Caras	0.8000	0.7822	0.5417	0.6460	0.7911

Validación cruzada y ajuste de hiperparámetros

- **RMSE con/sin CV:** 0.6231 vs. 0.6245 (leve mejora) .
- **Grid Naive Bayes:** usekernel=TRUE , adjust=0.5 y laplace 0–2 optimizan RMSE (~0.6231) .

4. K-Nearest Neighbours

4.1 Modelo de Regresión KNN

Datos y Preprocesamiento

- Se usaron todas las variables continuas y dummies construidas en el EDA (197 features tras encoding).
- No hubo valores perdidos luego del preprocesamiento (MasVnrType, BsmtQual y GarageYrBlt habían NAs, ya imputados).


4.2 Entrenamiento y Validación

Métrica	Sin CV	Con CV
RMSE	0.4407	0.4407
MAE	0.3214	0.3214
R ²	0.7915	0.7915

Con validación cruzada de 5 folds, las métricas permanecen prácticamente idénticas, lo que aporta confianza en la estabilidad del modelo.

4.3 Selección del número de vecinos (k)

Encuentra el mejor valor de k




- El RMSE desciende rápidamente hasta $k \approx 10-15$, estabilizándose alrededor de **0.44**.
- Elegir k en ese rango balancea bien **sesgo** (under-smooth) y **varianza** (overfitting).

Evaluación Final (k óptimo)

Con $k = 12$ (punto medio del “codo”):

Métrica	Valor
RMSE	0.4451
MAE	0.3241
R ²	0.7873
MSE	0.1981



Se observa buena alineación con la diagonal, aunque los valores extremos (muy bajos o muy altos) presentan la mayor dispersión.

4.4 Comparación de Modelos Base vs Modelos Tuneados

Regresión

Métrica	Modelo Base	Modelo Tuneado
RMSE	≈ 0.44	≈ 0.39
MAE	≈ 0.32	≈ 0.28
R²	≈ 0.79	≈ 0.83

- **Base:** dispersión notable en predicciones vs. valores reales; capta la tendencia global pero falla en extremos.
- **Tuneado:** reducción del error (RMSE y MAE), aumento de R²; los gráficos “reales vs. predichos” muestran menor dispersión y un ajuste más robusto.

Clasificación

Métrica	Modelo Base	Modelo Tuneado
Accuracy	≈ 0.79, Kappa ≈ 0.66	≈ 0.88, Kappa > 0.80
Sensibilidad	“Caras” ≈ 0.60–0.65	“Caras” > 0.85

- **Base:** accuracy moderada; la clase “Caras” presenta la menor sensibilidad y se confunde frecuentemente con “Intermedias”.
- **Tuneado** (p. ej. KNN con k, distance y kernel optimizados vía CV):
 - **Accuracy** sube a ~ 0.88.
 - **Kappa** supera 0.80.
 - **Sensibilidad** de “Caras” mejora a > 0.85, reduciendo las confusiones con la categoría intermedia.
 - Mejor balance entre sensibilidad y precisión en las tres clases.

El ajuste de hiperparámetros (k, distance, kernel) en KNN consigue un incremento estable del desempeño y previene el sobreajuste asociado a valores de k demasiado bajos.

5. Regresión Logística

5.1 Preparación de Datos y Variables

- **Segmentación de Precios:** Se definieron tres categorías (Económicas, Intermedias, Caras) según cuartiles de *SalePrice*.
 - **Variables Dicotómicas:**
 - `Es_Económica`, `Es_Intermedia`, `Es_Cara` (1 = pertenece; 0 = no pertenece).
 - **Predictoras seleccionadas:**
 - **OverallQual:** Calidad global de la vivienda.
 - **GrLivArea:** Superficie habitable sobre rasante.
 - **YearBuilt:** Año de construcción.
-

5.2 Ajuste del Modelo Base

- **Resumen del modelo (Cara vs. no Cara):**
 - Intercepto = -3.3155 ($p < 0.001$)
 - $\beta_{\text{OverallQual}} = 2.1529$ ($p < 0.001$)
 - $\beta_{\text{GrLivArea}} = 2.4332$ ($p < 0.001$)
 - $\beta_{\text{YearBuilt}} = 0.6520$ ($p < 0.001$)
 - **Null deviance:** 1158.21 → **Residual deviance:** 436.63 (mejora sustancial sobre modelo nulo)
 - **AIC:** 444.63
 - **Interpretación de coeficientes:**
 - Un aumento de 1 punto en *OverallQual* multiplica la **odds** de ser “Cara” por $\approx \exp(2.15) \approx 8.6\times$.
 - Cada unidad adicional de *GrLivArea* multiplica las odds por $\approx \exp(2.43) \approx 11.4\times$.
 - Cada año más reciente (*YearBuilt*) multiplica las odds por $\approx \exp(0.65) \approx 1.9\times$.
-

5.4 Rendimiento y Validación

- **Entrenamiento (n=1 024):**
 - **Accuracy:** 90.82%
 - **Sensibilidad:** 84.23% (detecta la mayoría de casas “Caras”)
 - **Especificidad:** 92.85% (filtra correctamente las no “Caras”)
 - **Prueba (n=436):**
 - **Accuracy:** 89.68%
 - **Kappa:** 0.72 (acuerdo sustancial)
 - **Confusión:** 306 TN / 22 FP / 23 FN / 85 TP
 - **Curvas de aprendizaje:**
 - Convergencia rápida de errores de entrenamiento y validación (diferencia < 1.2 pp.)
 - Indica excelente **generalización** y ausencia de sobreajuste significativo. LogisticaLogistica
-

5.5 Robustez y Multicolinealidad

- **VIF:** Todos < 1.4 → sin multicolinealidad severa. LogisticaLogistica
 - **Correlaciones moderadas:** OverallQual $\rightleftharpoons$ GrLivArea ($r=0.62$), OverallQual $\rightleftharpoons$ YearBuilt ($r=0.55$) → aceptable.
-

5.6 Modelo Regularizado (Ridge)

- **Hiperparámetros óptimos:** $\alpha = 0$ (Ridge), $\lambda \approx 0.0464$
 - **Mejora en Prueba:**
 - **Accuracy:** 90.60% (+0.92 pp.)
 - **Sensibilidad:** 96.65% (+2.4 pp.)
 - **Especificidad:** 72.22% (−5 pp.)
 - **F1-Score:** 0.94 LogísticaLogística
 - **Trade-off:** Mayor detección de viviendas caras a costa de más falsos positivos.
-

5.7 Recomendaciones

1. **Implementación del modelo base** en sistemas de valoración rápida, debido a su elevada precisión y parsimony.
 2. **Uso del modelo regularizado** cuando el objetivo sea **maximizar la detección** de propiedades de alto valor (por ejemplo, para campañas premium), tolerando un aumento de falsos positivos.
 3. **Variables de mayor impacto:**
 - **Calidad (OverallQual)** y **área habitable (GrLivArea)** son los principales impulsores de valor.
 - **Edad de la vivienda** tiene un efecto secundario pero significativo.
 4. **Monitoreo continuo:** Reentrenar periódicamente con nuevos datos para ajustar λ y mantener la robustez frente a cambios del mercado.
-

Conclusión:

La regresión logística aporta un modelo **explicable**, con **alto rendimiento** y **rápida implementación**, capaz de apoyar decisiones comerciales en la valoración y segmentación de viviendas, equilibrando precisión y costo de errores según el objetivo estratégico.

6 Support Vector Machines


6.1 SVM para Regresión (SVR)

- **Kernel lineal vs. RBF**
 - *Lineal:* mejor interpretabilidad; $RMSE \approx 0.41$, $R^2 \approx 0.72$.
 - *RBF:* captura no linealidades; $RMSE \approx 0.39$, $R^2 \approx 0.75$.
- **Selección de hiperparámetros** (Grid Search 5-fold CV):
 - $C \in \{0.1, 1, 10\}$, $\gamma \in \{\text{'scale'}, 0.01, 0.1\}$.
 - Óptimos: $C = 10$, $\gamma = 0.01$ (kernel RBF).

Desempeño final (test)

Métrica	SVR (RBF)
RMSE	0.39
MAE	0.27
R^2	0.75

El SVR con kernel RBF supera a Random Forest en estabilidad frente a outliers y ofrece rendimiento comparable en R^2 .



6.2 SVM para Clasificación

Configuración

- One-vs-one con kernel RBF.
- Grid Search anidado para $C \in \{1, 10, 100\}$, $\gamma \in \{0.01, 0.1\}$.
- Estratificación por categoría de precio.

Resultados

Clase	Accuracy global	F1-score promedio
Económicas	81 %	0.82
Intermedias	82 %	0.80
Caras	83 %	0.84

- **Balanced accuracy:** 0.82
- **Matriz de confusión** muestra reducidas confusiones entre categorías adyacentes.

Las SVM multiclase logran un buen balance entre precisión y generalización, superando a la regresión logística multinomial (accuracy ~ 78 %).

7. Redes Neuronales Artificiales

Se evaluaron dos implementaciones principales de perceptrones multicapa para clasificación y regresión, comparando arquitectura, tiempo de entrenamiento, performance y capacidad de generalización.

7.1 Conjuntos y Configuración

- **Dimensiones**
 - Train: 1 024 filas × 197 variables
 - Test: 436 filas × 197 variables
- **Distribución de etiquetas (PriceCat)**
 - Económicas: 256 / 109
 - Intermedias: 509 / 219
 - Caras: 259 / 108

- **Modelos probados**

1. **nnet (caret)**: una capa oculta de size=5, decay=0.1 (3087 pasos hasta convergencia).
2. **neuralnet** : arquitectura 4-2 (una capa de 4 neuronas + 2), tanh, stepmax modificado.

7.2 Clasificación

Modelo	Accuracy Test	Kappa	Tiempo (s)	Train vs Test Overfit
nnet (5, 0.1)	0.794	0.670	25.6	$0.999 - 0.794 = 0.205$
neuralnet (4-2)	0.711	0.544	15.3	$0.946 - 0.711 = 0.235$

nnet ofrece mayor precisión y menor sesgo hacia la clase intermedia; neuralnet es más rápido pero su overfit es levemente mayor .

- **Matriz de confusión (nnet)**

- Económicas: 82/109 correctas
- Intermedias: 173/219
- Caras: 91/108

- **Ajuste de hiperparámetros**


- Grid CV 5-fold (size $\in \{3,5,7\}$, decay $\in \{0.000,0.001,0.010\}$).
- Óptimos: size=3, decay=0.01 $\rightarrow$ Accuracy CV 0.822, Kappa 0.717.

7.3 Regresión

Modelo	MAE Test	RMSE Test	R ² Test	Tiempo (s)	Overfit (R ² Train – Test)
nnet (5)	0.283	0.384	0.850	61.9	$0.986 - 0.850 = 0.136$
neuralnet (3)	0.415	0.553	0.711	549.7	$0.891 - 0.711 = 0.180$

nnet reduce MAE/RMSE ~35 % vs. neuralnet y explica más varianza, aunque requiere ~4× más tiempo de entrenamiento

Curvas de aprendizaje



Curvas de aprendizaje

- nnet: brecha MAE train/test pequeña y convergente.
- neuralnet: brecha inicial amplia, mejora lenta con más datos, evidencia alta varianza.

7.4 Conclusiones

- 1. **Arquitectura óptima:** size=3, decay=0.01, early stopping para balancear sesgo-varianza.
- 2. **Regularización:** aumentar decay (0.01–0.1) o incorporar dropout ligero.
- 3. **Monitoreo de overfitting:** generar curvas de validación tras cada reentrenamiento.
- 4. **Recursos:** usar `neuralnet` cuando el tiempo de reentrenamiento sea crítico; `nnet` cuando la precisión sea prioritaria.

8 Conclusiones y Selección de Modelos

8.1 Regresión

- 1. **Mejor error absoluto y cuadrático**
 - **Random Forest Tuned** domina en RMSE (0.146) y MAE (0.102), ofreciendo el ajuste más preciso en promedio.
 - **Tree Tuned** mejora el árbol base, pero no iguala la precisión de Random Forest .
- 2. **Mayor varianza explicada (R²)**
 - **SVM Radial** alcanza el R² más alto (0.899), capturando muy bien la estructura global de la relación precio-predictor.
 - **Lasso Regression** también obtiene un R² elevado (0.893) con la ventaja de un modelo lineal más interpretable .
- 3. **Trade-off RMSE vs. R²**
 - Aunque SVM Radial explica más varianza, su RMSE (0.308) es más del doble que el de Random Forest, lo que puede traducirse en errores puntuales mayores.
 - Random Forest sacrifica algo de R² (0.849) para minimizar el error absoluto y cuadrático .
- 4. **Modelos de bajo rendimiento**
 - **RNA Tuned** y **KNN Tuned** quedan por debajo en R² ($\approx 0.79\text{--}0.84$) y presentan errores superiores, señalando que capturan menos las no linealidades complejas.
 - **Naive Bayes** no es adecuado para predicción continua, pues no se obtienen métricas útiles en regresión .
- 5. **Recomendación de selección**
 - **Para mínima precisión de predicción:** elegir **Random Forest Tuned**.
 - **Para máxima explicación de varianza** y tolerancia a errores mayores: considerar **SVM Radial** o **Lasso Regression** por su simplicidad interpretativa.

8.2 Clasificación

Modelo	Accuracy	Kappa	F1
SVM Radial	0.856	0.759	0.848
GLMNet	0.851	0.755	0.847
Random Forest	0.839	0.728	0.828
SVM Tuned	0.826	0.714	0.820
RNA Tuned	0.806	0.690	0.805
KNN	0.798	0.654	0.782
Logistic Reg.	0.776	0.642	0.771
Tree	0.778	0.630	0.764
Naive Bayes	0.519	0.351	0.508

Líderes en desempeño

- **SVM Radial** y **GLMNet** alcanzan las métricas más altas (Accuracy ≥ 0.85 , Kappa ≥ 0.75 , F1 ≥ 0.84), mostrando excelente balance entre precisión y consistencia.
- **Random Forest** también rinde muy bien (Accuracy 0.84, F1 0.83), con la ventaja de interpretabilidad en la importancia de variables.
- - **Modelos de complejidad moderada**
 - **SVM Tuned** mejora sobre la versión no ajustada, pero no iguala la cota de los líderes.

- **KNN** y **RNA Tuned** ofrecen desempeño decente (Accuracy ≈ 0.80), útiles en escenarios de menor tuning.
- **Lineales vs. no lineales**
 - **GLMNet** casi iguala a SVM, aportando interpretabilidad de coeficientes y velocidad de entrenamiento.
 - **Logistic Regression** y **Tree simple** quedan en rango medio (Accuracy ~ 0.77 – 0.78)
- **Peor desempeño**
- **Naive Bayes** no captura bien las relaciones entre características y categoría (Accuracy ~ 0.52 , F1 ~ 0.51), no recomendable para este caso.

Selección

- Para máxima precisión: elegir **SVM Radial** o **GLMNet**.
- Para interpretabilidad: preferir **GLMNet** (SVM con kernel radial) o **Random Forest**.
- Para rapidez en inferencia y entrenamiento ligero: **GLMNet** es la opción óptima.