

Entrega 4- KNN

Rodrigo Mansilla, Javier Chen

2025-02-25

Modelo de Regresión Knn

Conjunto de datos

	x
Id	0
MSSubClass	0
MSZoning	0
LotFrontage	0
LotArea	0
LotShape	0
LotConfig	0
Condition1	0
OverallQual	0
OverallCond	0
YearBuilt	0
YearRemodAdd	0
RoofStyle	0
MasVnrType	4
MasVnrArea	4
ExterQual	0
ExterCond	0
Foundation	0
BsmtQual	26
BsmtExposure	0
BsmtFinType1	0
BsmtFinSF1	0
BsmtFinSF2	0
BsmtUnfSF	0
TotalBsmtSF	0
HeatingQC	0
CentralAir	0
Electrical	0
X1stFlrSF	0
X2ndFlrSF	0
GrLivArea	0
BsmtFullBath	0
BsmtHalfBath	0
FullBath	0
HalfBath	0
BedroomAbvGr	0

	x
KitchenQual	0
TotRmsAbvGrd	0
Fireplaces	0
FireplaceQu	0
GarageType	0
GarageYrBlt	57
GarageFinish	0
GarageCars	0
GarageArea	0
PavedDrive	0
WoodDeckSF	0
OpenPorchSF	0
Fence	0
MoSold	0
YrSold	0
SaleType	0
SaleCondition	0
SalePrice	0
Neighborhood.Edwards	0
Neighborhood.Gilbert	0
Neighborhood.Names	0
Neighborhood.NridgHt	0
Neighborhood.OldTown	0
Neighborhood.Other	0
Neighborhood.Sawyer	0
Neighborhood.Somerst	0
BldgType.Other	0
BldgType.TwnhsE	0
HouseStyle.1Story	0
HouseStyle.2Story	0
HouseStyle.Other	0
Exterior1st.MetalSd	0
Exterior1st.Other	0
Exterior1st.Plywood	0
Exterior1st.VinylSd	0
Exterior1st.Wd.Sdng	0
Exterior2nd.MetalSd	0
Exterior2nd.Other	0
Exterior2nd.Plywood	0
Exterior2nd.VinylSd	0
Exterior2nd.Wd.Sdng	0
TotalArea	0
HouseAge	0
TotalBath	0


	x
Id	0
MSSubClass	0
MSZoning	0
LotFrontage	0

	x
LotArea	0
LotShape	0
LotConfig	0
Condition1	0
OverallQual	0
OverallCond	0
YearBuilt	0
YearRemodAdd	0
RoofStyle	0
MasVnrType	0
MasVnrArea	0
ExterQual	0
ExterCond	0
Foundation	0
BsmtQual	0
BsmtExposure	0
BsmtFinType1	0
BsmtFinSF1	0
BsmtFinSF2	0
BsmtUnfSF	0
TotalBsmtSF	0
HeatingQC	0
CentralAir	0
Electrical	0
X1stFlrSF	0
X2ndFlrSF	0
GrLivArea	0
BsmtFullBath	0
BsmtHalfBath	0
FullBath	0
HalfBath	0
BedroomAbvGr	0
KitchenQual	0
TotRmsAbvGrd	0
Fireplaces	0
FireplaceQu	0
GarageType	0
GarageYrBlt	0
GarageFinish	0
GarageCars	0
GarageArea	0
PavedDrive	0
WoodDeckSF	0
OpenPorchSF	0
Fence	0
MoSold	0
YrSold	0
SaleType	0
SaleCondition	0
SalePrice	0
Neighborhood.Edwards	0
Neighborhood.Gilbert	0

	x
Neighborhood.NAmes	0
Neighborhood.NridgHt	0
Neighborhood.OldTown	0
Neighborhood.Other	0
Neighborhood.Sawyer	0
Neighborhood.Somerst	0
BldgType.Other	0
BldgType.TwnhsE	0
HouseStyle.1Story	0
HouseStyle.2Story	0
HouseStyle.Other	0
Exterior1st.MetalSd	0
Exterior1st.Other	0
Exterior1st.Plywood	0
Exterior1st.VinylSd	0
Exterior1st.Wd.Sdng	0
Exterior2nd.MetalSd	0
Exterior2nd.Other	0
Exterior2nd.Plywood	0
Exterior2nd.VinylSd	0
Exterior2nd.Wd.Sdng	0
TotalArea	0
HouseAge	0
TotalBath	0

Entrenamiento del modelo

Gráficos de predicción




Evaluación del modelo

RMSE	MAE	R2
0.4406691	0.3213652	0.7915463

- El **modelo base** de kNN muestra un desempeño bueno, con un R^2 cerca de 0.79 y errores (RMSE y MAE) moderados.
- La dispersión en la gráfica de predicción sugiere que todavía hay margen de mejora, sobre todo en los casos de precios muy bajos o muy altos, que son más difíciles de aproximar con un kNN base.

Modelo de Regresión Knn con CV

Gráficos de predicción




Evaluación del modelo

RMSE	MAE	R2
0.4406691	0.3213652	0.7915463


- **Desempeño:** RMSE 0.44, MAE 0.32 y R^2 0.79 indican un ajuste sólido; el modelo explica la mayor parte de la variabilidad en el precio.
- **Comparación con Modelo Base:** Las métricas son similares, pero la validación cruzada aporta mayor confianza en los resultados al reducir la dependencia de una única partición
- **Gráfico de Predicción:** Los puntos predichos siguen de cerca a los reales, aunque existen discrepancias en valores muy bajos y altos.

Entrenamiento del modelo con variación de k


Encuentra el mejor valor de k



Gráficos de predicción



Gráficos de Residuos



Evaluación del modelo


RMSE	MAE	R2	MSE
0.4450964	0.3240914	0.7873367	0.1981108

- **Mejor k:** En la curva , el error cae rápidamente hasta $k=10-15$ y después se estabiliza cerca de 0.44, indicando que ese rango de k equilibra bien sesgo y varianza.
- **Métricas Finales:** $RMSE=0.445$, $MAE=0.324$, $R^2=0.787$ muestran que el modelo explica $\sim 79\%$ de la variabilidad en el precio, con un error medio moderado.
- **Gráficos de Predicción y Residuos:**
 - Los valores predichos siguen la tendencia de los valores reales , pero existen desviaciones en extremos.
 - Los residuos se concentran cerca de 0, si bien algunos valores muy altos/bajos se alejan más, reflejando mayor dificultad en esos rangos.

Comparación de modelos


Modelo de Naive Bayes

Gráficos de predicción




Modelo de Árbol de Regresión

Gráficos de predicción




Modelo de Random Forest

Gráficos de predicción



Modelo de Regresión lineal

Gráficos de predicción




Comparación de modelos

Model	RMSE	MAE	MSE	R2
Naive Bayes	0.5570518	0.4295844	0.3103068	0.6462258

Model	RMSE	MAE	MSE	R2
Linear Regression	0.3255845	0.2078932	0.1060053	0.8791456
Tree Regression	0.4913844	0.3649747	0.2414586	0.7247181
Random Forest	0.3621681	0.2442799	0.1311657	0.8504608
KNN	0.4406691	0.3213652	0.1941893	0.7915463

Gráficos de comparación



Resumen Breve de Comparación de Modelos

Naive Bayes

- **RMSE=0.557, $R^2=0.646$**
- Predicciones muy discretas (líneas horizontales), lo que indica menor ajuste a la variabilidad real.

Árbol de Regresión

- **RMSE=0.491, $R^2=0.724$**
- Muestra escalones en la predicción (típico de un único árbol) y un desempeño intermedio.

Random Forest

- **RMSE=0.362, $R^2=0.850$**
- Acierta mejor que el árbol base gracias al ensamble de múltiples árboles, capturando mejor la complejidad de los datos.

kNN

- **RMSE**=0.441, **R**²=0.792
- Buen ajuste en general, pero no tan alto como el Random Forest o la regresión lineal. Los valores extremos siguen siendo difíciles de predecir.

Regresión Lineal

- **RMSE**=0.326, **R**²=0.879
- Es el modelo más preciso según estas métricas, con predicciones muy cercanas a la diagonal de “valor real = predicción”.

Conclusión: La **Regresión Lineal** logra el mejor desempeño global. Le sigue de cerca el **Random Forest**, que captura no linealidades y mantiene un error bajo. **kNN** se ubica en tercer lugar, mientras que el **Árbol de Regresión** y **Naive Bayes** presentan el error más alto y menor **R**².

Modelo de Clasificación Knn

Se usa la variable PriceCat

Var1	Freq
Economicas	230
Intermedias	472
Caras	238

Var1	Freq
Economicas	96
Intermedias	201
Caras	100

Entrenamiento del modelo

Table 9: Valor de k

x
31

Predicción del modelo y evaluación

Table 10: Matriz de Confusión

Prediction	Reference	Freq
Economicas	Economicas	84
Intermedias	Economicas	12
Caras	Economicas	0
Economicas	Intermedias	27

Intermedias	Intermedias	171
Caras	Intermedias	3
Economicas	Caras	0
Intermedias	Caras	40
Caras	Caras	60

Table 11: Métricas Globales

Accuracy	Kappa	AccuracyLower	AccuracyUpper	AccuracyNull	AccuracyPValue	McNemarPValue
0.7934509	0.6602943	0.7502463	0.8322168	0.5062972	0	NaN

Table 12: Métricas por Clase

	Sensitivity	Specificity	Pos Pred Value	Neg Pred Value	Precision	Recall	F1	Prevalence	Detection Rate	Detection Prevalence	Balanced Accuracy
Class: Economicas	0.8750000	0.9102990	0.7567568	0.9580420	0.7567568	0.8750000	0.8115942	0.2418136	0.2115869	0.2795970	0.8926495
Class: Intermedias	0.8507463	0.7346939	0.7668161	0.8275862	0.7668161	0.8507463	0.8066038	0.5062972	0.4307305	0.5617128	0.7927201
Class: Caras	0.6000000	0.9898990	0.9523810	0.8802395	0.9523810	0.6000000	0.7361963	0.2518892	0.1511335	0.1586902	0.7949495

Efectividad Global

Accuracy 79.3% y Kappa 0.66

El modelo acierta casi el 80% de las veces y muestra un acuerdo bueno por encima de lo esperado al azar (Kappa > 0.6).

Análisis de la Matriz de Confusión

Clase “Económicas”

- **Sensitivity = 0.875:** De cada 100 casas realmente económicas, 87–88 se clasifican correctamente.
- **Specificity = 0.910:** Muy pocas veces confunde otros tipos (Intermedias/Caras) como Económicas.
- **Error principal:** ocurre cuando las Económicas son predichas como “Intermedias” (12 casos), pero la magnitud es relativamente baja.

Clase “Intermedias”

- **Sensitivity = 0.8507:** Reconoce un 85% de las Intermedias reales.
- **Specificity = 0.7347:** Mayor probabilidad de confundir otras clases como Intermedias; esto implica más “falsos positivos”.
- **Error principal:** Parte de las Intermedias acaban clasificadas como “Económicas” o “Caras”, y viceversa (p. ej., 40 Caras confundidas como Intermedias).

Clase “Caras”

- **Sensitivity = 0.60:** Solo identifica 60% de las viviendas caras, es decir, pierde el 40% restante.
- **Specificity = 0.9899:** Cuando una casa no es cara, casi siempre lo acierta.
- **Error principal:** Varias casas realmente “Caras” son etiquetadas como “Intermedias” (40 casos), disminuyendo la sensibilidad.

Dónde se Equivoca Más y Dónde Menos

- **Menos Errores:** En “Económicas”, gracias a su alta sensibilidad y especificidad (~87.5% y 91%).
- **Más Errores:** En “Caras”, ya que la sensibilidad es la más baja (0.60). El modelo subestima o confunde las viviendas caras con “Intermedias”.
- “Intermedias” mantiene un balance aceptable, pero sigue siendo una clase amplia que se presta a confusiones con las otras dos.

Importancia de los Errores

- Subestimar viviendas Caras podría impactar negativamente en estrategias de venta Y se pierden oportunidades de precio alto.
- Confundir Económicas como Intermedias o viceversa puede afectar la estimación de valor de mercado y segmentación de clientes.

Conclusión

El modelo alcanza un buen rendimiento global (**accuracy 79%**) y clasifica con notable precisión las categorías “Económicas” e “Intermedias”. Sin embargo, fallar en “Caras” es la principal debilidad, lo que sugiere que para identificar casas de alto valor es necesario evaluar estrategias como el ajuste de k , refinar variables entre otras alternativas.