

Entrega 4- KNN

Rodrigo Mansilla, Javier Chen

2025-02-25

Modelo de Regresión Knn

Conjunto de datos

	x
Id	0
MSSubClass	0
MSZoning	0
LotFrontage	0
LotArea	0
LotShape	0
LotConfig	0
Condition1	0
OverallQual	0
OverallCond	0
YearBuilt	0
YearRemodAdd	0
RoofStyle	0
MasVnrType	4
MasVnrArea	4
ExterQual	0
ExterCond	0
Foundation	0
BsmtQual	26
BsmtExposure	0
BsmtFinType1	0
BsmtFinSF1	0
BsmtFinSF2	0
BsmtUnfSF	0
TotalBsmtSF	0
HeatingQC	0
CentralAir	0
Electrical	0
X1stFlrSF	0
X2ndFlrSF	0
GrLivArea	0
BsmtFullBath	0
BsmtHalfBath	0
FullBath	0
HalfBath	0
BedroomAbvGr	0

	x
KitchenQual	0
TotRmsAbvGrd	0
Fireplaces	0
FireplaceQu	0
GarageType	0
GarageYrBlt	57
GarageFinish	0
GarageCars	0
GarageArea	0
PavedDrive	0
WoodDeckSF	0
OpenPorchSF	0
Fence	0
MoSold	0
YrSold	0
SaleType	0
SaleCondition	0
SalePrice	0
Neighborhood.Edwards	0
Neighborhood.Gilbert	0
Neighborhood.Names	0
Neighborhood.NridgHt	0
Neighborhood.OldTown	0
Neighborhood.Other	0
Neighborhood.Sawyer	0
Neighborhood.Somerst	0
BldgType.Other	0
BldgType.TwnhsE	0
HouseStyle.1Story	0
HouseStyle.2Story	0
HouseStyle.Other	0
Exterior1st.MetalSd	0
Exterior1st.Other	0
Exterior1st.Plywood	0
Exterior1st.VinylSd	0
Exterior1st.Wd.Sdng	0
Exterior2nd.MetalSd	0
Exterior2nd.Other	0
Exterior2nd.Plywood	0
Exterior2nd.VinylSd	0
Exterior2nd.Wd.Sdng	0
TotalArea	0
HouseAge	0
TotalBath	0


	x
Id	0
MSSubClass	0
MSZoning	0
LotFrontage	0

	x
LotArea	0
LotShape	0
LotConfig	0
Condition1	0
OverallQual	0
OverallCond	0
YearBuilt	0
YearRemodAdd	0
RoofStyle	0
MasVnrType	0
MasVnrArea	0
ExterQual	0
ExterCond	0
Foundation	0
BsmtQual	0
BsmtExposure	0
BsmtFinType1	0
BsmtFinSF1	0
BsmtFinSF2	0
BsmtUnfSF	0
TotalBsmtSF	0
HeatingQC	0
CentralAir	0
Electrical	0
X1stFlrSF	0
X2ndFlrSF	0
GrLivArea	0
BsmtFullBath	0
BsmtHalfBath	0
FullBath	0
HalfBath	0
BedroomAbvGr	0
KitchenQual	0
TotRmsAbvGrd	0
Fireplaces	0
FireplaceQu	0
GarageType	0
GarageYrBlt	0
GarageFinish	0
GarageCars	0
GarageArea	0
PavedDrive	0
WoodDeckSF	0
OpenPorchSF	0
Fence	0
MoSold	0
YrSold	0
SaleType	0
SaleCondition	0
SalePrice	0
Neighborhood.Edwards	0
Neighborhood.Gilbert	0

	x
Neighborhood.NAmes	0
Neighborhood.NridgHt	0
Neighborhood.OldTown	0
Neighborhood.Other	0
Neighborhood.Sawyer	0
Neighborhood.Somerst	0
BldgType.Other	0
BldgType.TwnhsE	0
HouseStyle.1Story	0
HouseStyle.2Story	0
HouseStyle.Other	0
Exterior1st.MetalSd	0
Exterior1st.Other	0
Exterior1st.Plywood	0
Exterior1st.VinylSd	0
Exterior1st.Wd.Sdng	0
Exterior2nd.MetalSd	0
Exterior2nd.Other	0
Exterior2nd.Plywood	0
Exterior2nd.VinylSd	0
Exterior2nd.Wd.Sdng	0
TotalArea	0
HouseAge	0
TotalBath	0

Entrenamiento del modelo

Gráficos de predicción




Evaluación del modelo

RMSE	MAE	R2
0.4406691	0.3213652	0.7915463

- El **modelo base** de kNN muestra un desempeño bueno, con un R^2 cerca de 0.79 y errores (RMSE y MAE) moderados.
- La dispersión en la gráfica de predicción sugiere que todavía hay margen de mejora, sobre todo en los casos de precios muy bajos o muy altos, que son más difíciles de aproximar con un kNN base.

Modelo de Regresión Knn con CV

Gráficos de predicción




Evaluación del modelo

RMSE	MAE	R2
0.4406691	0.3213652	0.7915463


- **Desempeño:** RMSE 0.44, MAE 0.32 y R^2 0.79 indican un ajuste sólido; el modelo explica la mayor parte de la variabilidad en el precio.
- **Comparación con Modelo Base:** Las métricas son similares, pero la validación cruzada aporta mayor confianza en los resultados al reducir la dependencia de una única partición
- **Gráfico de Predicción:** Los puntos predichos siguen de cerca a los reales, aunque existen discrepancias en valores muy bajos y altos.

Entrenamiento del modelo con variación de k


Encuentra el mejor valor de k



Gráficos de predicción



Gráficos de Residuos



Evaluación del modelo


RMSE	MAE	R2	MSE
0.4450964	0.3240914	0.7873367	0.1981108

- **Mejor k:** En la curva , el error cae rápidamente hasta $k=10-15$ y después se estabiliza cerca de 0.44, indicando que ese rango de k equilibra bien sesgo y varianza.
- **Métricas Finales:** $RMSE=0.445$, $MAE=0.324$, $R^2=0.787$ muestran que el modelo explica $\sim 79\%$ de la variabilidad en el precio, con un error medio moderado.
- **Gráficos de Predicción y Residuos:**
 - Los valores predichos siguen la tendencia de los valores reales , pero existen desviaciones en extremos.
 - Los residuos se concentran cerca de 0, si bien algunos valores muy altos/bajos se alejan más, reflejando mayor dificultad en esos rangos.

Comparación de modelos


Modelo de Naive Bayes

Gráficos de predicción




Modelo de Árbol de Regresión

Gráficos de predicción




Modelo de Random Forest

Gráficos de predicción



Modelo de Regresión lineal

Gráficos de predicción




Comparación de modelos

Model	RMSE	MAE	MSE	R2
Naive Bayes	0.5570518	0.4295844	0.3103068	0.6462258

Model	RMSE	MAE	MSE	R2
Linear Regression	0.3255845	0.2078932	0.1060053	0.8791456
Tree Regression	0.4913844	0.3649747	0.2414586	0.7247181
Random Forest	0.3621681	0.2442799	0.1311657	0.8504608
KNN	0.4406691	0.3213652	0.1941893	0.7915463

Gráficos de comparación



Resumen Breve de Comparación de Modelos

Naive Bayes

- **RMSE=0.557, $R^2=0.646$**
- Predicciones muy discretas (líneas horizontales), lo que indica menor ajuste a la variabilidad real.

Árbol de Regresión

- **RMSE=0.491, $R^2=0.724$**
- Muestra escalones en la predicción (típico de un único árbol) y un desempeño intermedio.

Random Forest

- **RMSE=0.362, $R^2=0.850$**
- Acierta mejor que el árbol base gracias al ensamble de múltiples árboles, capturando mejor la complejidad de los datos.

kNN

- **RMSE**=0.441, **R²**=0.792
- Buen ajuste en general, pero no tan alto como el Random Forest o la regresión lineal. Los valores extremos siguen siendo difíciles de predecir.

Regresión Lineal

- **RMSE**=0.326, **R²**=0.879
- Es el modelo más preciso según estas métricas, con predicciones muy cercanas a la diagonal de “valor real = predicción”.

Conclusión: La **Regresión Lineal** logra el mejor desempeño global. Le sigue de cerca el **Random Forest**, que captura no linealidades y mantiene un error bajo. **kNN** se ubica en tercer lugar, mientras que el **Árbol de Regresión** y **Naive Bayes** presentan el error más alto y menor **R²**.

Modelo de Clasificación Knn

Se usa la variable PriceCat

Var1	Freq
Economicas	230
Intermedias	472
Caras	238

Var1	Freq
Economicas	96
Intermedias	201
Caras	100

Entrenamiento del modelo

Table 9: Valor de k

x
31

Predicción del modelo y evaluación

Table 10: Matriz de Confusión

Prediction	Reference	Freq
Economicas	Economicas	84
Intermedias	Economicas	12
Caras	Economicas	0
Economicas	Intermedias	27

Intermedias	Intermedias	171
Caras	Intermedias	3
Economicas	Caras	0
Intermedias	Caras	40
Caras	Caras	60

Table 11: Métricas Globales

Accuracy	Kappa	AccuracyLower	AccuracyUpper	AccuracyNull	AccuracyPValue	McnemarPValue
0.7934509	0.6602943	0.7502463	0.8322168	0.5062972	0	NaN

Table 12: Métricas por Clase

	Sensitivity	Specificity	Pos Pred Value	Neg Pred Value	Precision	Recall	F1	Prevalence	Detection Rate	Detection Prevalence	Balanced Accuracy
Class: Economicas	0.8750000	0.9102990	0.7567568	0.9580420	0.7567568	0.8750000	0.8115942	0.2418136	0.2115869	0.2795970	0.8926495
Class: Intermedias	0.8507463	0.7346939	0.7668161	0.8275862	0.7668161	0.8507463	0.8066038	0.5062972	0.4307305	0.5617128	0.7927201
Class: Caras	0.6000000	0.9898990	0.9523810	0.8802395	0.9523810	0.6000000	0.7361963	0.2518892	0.1511335	0.1586902	0.7949495

Efectividad Global

Accuracy 79.3% y Kappa 0.66

El modelo acierta casi el 80% de las veces y muestra un acuerdo bueno por encima de lo esperado al azar (Kappa > 0.6).

Análisis de la Matriz de Confusión

Clase “Económicas”

- **Sensitivity = 0.875:** De cada 100 casas realmente económicas, 87–88 se clasifican correctamente.
- **Specificity = 0.910:** Muy pocas veces confunde otros tipos (Intermedias/Caras) como Económicas.
- **Error principal:** ocurre cuando las Económicas son predichas como “Intermedias” (12 casos), pero la magnitud es relativamente baja.

Clase “Intermedias”

- **Sensitivity = 0.8507:** Reconoce un 85% de las Intermedias reales.
- **Specificity = 0.7347:** Mayor probabilidad de confundir otras clases como Intermedias; esto implica más “falsos positivos”.
- **Error principal:** Parte de las Intermedias acaban clasificadas como “Económicas” o “Caras”, y viceversa (p. ej., 40 Caras confundidas como Intermedias).

Clase “Caras”

- **Sensitivity = 0.60:** Solo identifica 60% de las viviendas caras, es decir, pierde el 40% restante.
- **Specificity = 0.9899:** Cuando una casa no es cara, casi siempre lo acierta.
- **Error principal:** Varias casas realmente “Caras” son etiquetadas como “Intermedias” (40 casos), disminuyendo la sensibilidad.

Dónde se Equivoca Más y Dónde Menos


- **Menos Errores:** En “Económicas”, gracias a su alta sensibilidad y especificidad (~87.5% y 91%).
- **Más Errores:** En “Caras”, ya que la sensibilidad es la más baja (0.60). El modelo subestima o confunde las viviendas caras con “Intermedias”.
- “Intermedias” mantiene un balance aceptable, pero sigue siendo una clase amplia que se presta a confusiones con las otras dos.

Importancia de los Errores

- Subestimar viviendas Caras podría impactar negativamente en estrategias de venta Y se pierden oportunidades de precio alto.
- Confundir Económicas como Intermedias o viceversa puede afectar la estimación de valor de mercado y segmentación de clientes.

El modelo alcanza un buen rendimiento global (**accuracy 79%**) y clasifica con notable precisión las categorías “Económicas” e “Intermedias”. Sin embargo, fallar en “Caras” es la principal debilidad, lo que sugiere que para identificar casas de alto valor es necesario evaluar estrategias como el ajuste de k , refinar variables entre otras alternativas.

Analisis de sobreajuste



En la gráfica se ve que, con valores de k muy bajos (1–3), la exactitud en entrenamiento es mucho mayor que en prueba, lo cual indica sobreajuste en esos puntos el modelo memoriza el conjunto de entrenamiento y no generaliza bien. A medida que k aumenta, esa brecha se reduce, mitigando el sobreajuste. Por tanto, sí puede estar sobreajustado si se elige un k demasiado pequeño. El “óptimo” suele hallarse donde la curva roja alcanza su punto más alto sin que la azul sea demasiado baja, el cual de acuerdo a la gráfica esta en k=7.

Modelo de Clasificación con CV

Mejor k

Table 13: Mejor valor de k encontrado

x
29

Predicción y Evaluación del Modelo

Matriz de Confusión

Table 14: Matriz de Confusión del Modelo con CV

Prediction	Reference	Freq
Economicas	Economicas	196
Intermedias	Economicas	60
Caras	Economicas	0

Economicas	Intermedias	43
Intermedias	Intermedias	448
Caras	Intermedias	18
Economicas	Caras	0
Intermedias	Caras	81
Caras	Caras	178

****Clase “Económicas**** - 196 se clasifican correctamente como “Económicas”.
- 60 se confunden como “Intermedias”.
- Cero confusiones con “Caras”.

****Clase “Intermedias**** - 448 correctas como “Intermedias”.
- 43 se predicen por error como “Económicas”, 18 como “Caras”.

Clase Caras - 178 se aciertan como “Caras”.
- 81 casos realmente “Caras” se confunden como “Intermedias”.

El mayor equívoco aparece en la clase “Caras” → “Intermedias”.
“Económicas” y “Caras” casi nunca se confunden directamente entre sí.

Métricas Globales

Table 15: Métricas Globales del Modelo con CV

Accuracy	Kappa	AccuracyLower	AccuracyUpper	AccuracyNull	AccuracyPValue	McnemarPValue
0.8027344	0.6751897	0.7770174	0.8266975	0.4970703	0	NaN

Accuracy = 0.8027

El modelo acierta el 80.27% de los casos al clasificar viviendas en Económicas, Intermedias o Caras.

Kappa = 0.6752

Muestra un acuerdo “bueno” (por encima de 0.6) entre las predicciones y la realidad, restando el efecto del azar.

Intervalo de Confianza

- AccuracyLower = 0.7770
- AccuracyUpper = 0.8267

Confirma que la exactitud del modelo, bajo distintas particiones, se ubica aproximadamente entre 77.7% y 82.7%.

El modelo mantiene un desempeño sólido en clasificación, con buena concordancia global.

Table 16: Métricas por Clase del Modelo con CV

	Sensitivity	Specificity	Pos Pred Value	Neg Pred Value	Precision	Recall	F1	Prevalence	Detection Rate	Detection Prevalence	Balanced Accuracy
Class: Economicas	0.7656250	0.9440104	0.8200837	0.9235669	0.8200837	0.7656250	0.7919192	0.2500000	0.1914062	0.2333984	0.8548177
Class: Intermedias	0.8801572	0.7262136	0.7606112	0.8597701	0.7606112	0.8801572	0.8160291	0.4970703	0.4375000	0.5751953	0.8031854
Class: Caras	0.6872587	0.9764706	0.9081633	0.9021739	0.9081633	0.6872587	0.7824176	0.2529297	0.1738281	0.1914062	0.8318646

Métricas por Clase Clase “Económicas** - Sensibilidad **0.77**: detecta ~77% de las viviendas económicas.

- **Specificity 0.94**: muy pocas veces confunde otras clases como “Económicas”.
- **F1 = 0.792****: equilibra bien entre precisión (0.8201) y recall (0.7656).

Clase “Intermedias - Sensibilidad 0.88:** identifica la mayoría de casas “Intermedias”.
 - **Specificity 0.73:** un % considerable de otros tipos se marcan erróneamente como “Intermedias”.
 - **F1 = 0.816**:** la clase mejor equilibrada en términos de precisión y sensibilidad.

Clase Caras - Sensibilidad 0.69: aproximadamente 69% de las “Caras” se clasifican bien, quedando 31% confundidas.

- **Specificity 0.98:** casi nunca etiqueta viviendas no caras como “Caras”.
 - **F1 = 0.782:** moderado, mejor que el modelo sin CV (que tenía ~0.60 de sensibilidad).

El modelo sobresale en “Intermedias”, pero “Caras” muestra la sensibilidad más baja. “Económicas” balancea buena especificidad con sensibilidad decente.

Cálculo y presentación de F1-score por clase

Table 17: F1-score por Clase (Modelo con CV)

	Clase	F1_Score
Class: Economicas	Class: Economicas	0.792
Class: Intermedias	Class: Intermedias	0.816
Class: Caras	Class: Caras	0.782

Se observa que las tres clases tienen F1 por encima de 0.78, lo que indica un buen desempeño homogéneo. “Intermedias” destaca ligeramente (0.816), mientras “Caras” mejora frente al modelo previo, aunque sigue siendo la categoría menos sensible.

Comparación con modelo base

El modelo con validación cruzada (CV) obtuvo una exactitud algo mayor (0.8027 vs. 0.7934) y un Kappa superior (0.675 vs. 0.660), además de mejorar la identificación de la clase “Caras” (sensibilidad sube de 0.60 a ~0.69). Por tanto, funcionó mejor que el modelo anterior sin CV.

Modelo de regresión y clasificación con fine tuning

Para kNN, los hiperparámetros clave son: - kmax: número máximo de vecinos a considerar. El k elegido finalmente estará entre 1 y kmax, ajustado internamente por kkn.

- distance: tipo de distancia , 1 = Manhattan, 2 = Euclidiana, etc..
- kernel: cómo se ponderan los vecinos, por ejemplo, “rectangular” sin ponderación, “triangular” asigna más peso a los vecinos cercanos, “epanechnikov”, etc.

Modelo de Regresión

Table 18: Mejor Combinación de Hiperparámetros del Modelo KNN Tuneado


	kmax	distance	kernel
10	13	1	triangular

Predicción y Evaluación del Modelo de Regresión

Table 19: Métricas de Evaluación del Modelo KNN Tunado

Métrica	Valor
RMSE	0.3947
MAE	0.2842
MSE	0.1558
R-squared	0.8327

Graficos de predicciones



Modelo de Clasificación

Table 20: Mejor Combinación de Hiperparámetros del Modelo KNN Tuneado

kmax	distance	kernel
3	2	rectangular

Predicción y Evaluación del Modelo de Clasificación

Matriz de Confusión

Table 21: Matriz de Confusión del Modelo KNN (Clasificación)

Referencia	Predicción	Frecuencia
Economicas	Economicas	228

Intermedias	Economicas	28
Caras	Economicas	0
Economicas	Intermedias	40
Intermedias	Intermedias	453
Caras	Intermedias	16
Economicas	Caras	2
Intermedias	Caras	37
Caras	Caras	220

Métricas Globales

Table 22: Métricas Globales del Modelo KNN (Clasificación)

Métrica	Accuracy	Kappa	AccuracyLower	AccuracyUpper	AccuracyNull	AccuracyPValue	McNemarPValue
1	0.8798828	0.8076099	0.8583837	0.8991687	0.4970703	0	0.0060228

Métricas por clase

Table 23: Métricas por Clase

	Métrica	Sensitivity	Specificity	Pos Pred Value	Neg Pred Value	Precision	Recall	F1
Class: Economicas	Class: Economicas	0.8906250	0.9453125	0.8444444	0.9628647	0.8444444	0.8906250	0.8669202
Class: Intermedias	Class: Intermedias	0.8899804	0.8737864	0.8745174	0.8893281	0.8745174	0.8899804	0.8821811
Class: Caras	Class: Caras	0.8494208	0.9790850	0.9322034	0.9505076	0.9322034	0.8494208	0.8888889

Comparación de Modelos de Regresión y Clasificación con el Modelo Base

Modelo de Regresión

- **Modelo Base:**
 - RMSE 0.44, MAE 0.32, R^2 0.79.
 - Gráficamente, se observa dispersión en los valores predichos frente a los reales; aunque el modelo capta la tendencia global, hay espacio para mejorar en los extremos.
- **Modelo Tuneado:**
 - RMSE baja a ~0.39, R^2 sube a ~0.83, y la MAE también se reduce (~0.28).
 - Esto significa más precisión y mayor poder explicativo (R^2).
 - La dispersión en los gráficos de “valores reales vs. predichos” disminuye, reflejando un ajuste más robusto.

Modelo de Clasificación

- **Modelo Base**
 - Accuracy ~0.79, Kappa ~0.66.
 - Sensibilidad de la clase “Caras” es el punto más débil.
 - El modelo confunde varias “Caras” como “Intermedias”.

- **Modelo Tuneado:**

- Ajuste de kmax, distance, kernel con validación cruzada.
- El **accuracy** sube hasta ~0.88, y la **Kappa** aumenta >0.80 en ciertos casos.
- La sensibilidad de “Caras” mejora significativamente en 0.85, indicando menos confusión de viviendas de alto precio con la categoría Intermedia.
- Se logra un mejor equilibrio de sensibilidad y precisión en las tres clases.

A partir de estos hallazgos es posible argumentar que en comparación a los modelos base el tuneo de los parámetros en knn aumenta el desempeño de manera más estable y evita un k que sobreajuste los datos.


Comparación de Modelos de Clasificación

Métricas de Evaluación

Table 24: Comparación de Métricas de Modelos de Clasificación

Model	Accuracy	Kappa	F1
Tree Base	0.8232	0.7112	0.8167
Tree CV	0.8232	0.7112	0.8167
Random Forest	1.0000	1.0000	1.0000
Naive Bayes	0.5986	0.4386	0.5971
KNN	0.8037	0.6767	0.7978

Gráficos de Predicciones



Eficiencia y Métricas de Desempeño

1. Random Forest

- **Accuracy = 1.00, Kappa = 1.00, F1 = 1.00**
- Registra métricas perfectas en esta tabla. Puede deberse a un conjunto de datos relativamente pequeño o a un sobreajuste marcado; en cualquier caso, destaca como el de mayor exactitud.

2. Árbol de Decisión (Base / CV)

- **Accuracy 0.8232, Kappa 0.71, F1 0.817**
- El mismo desempeño tanto en "Tree Base" como "Tree CV".

3. kNN

- **Accuracy 0.8037, Kappa 0.6767, F1 0.798**
- Un desempeño sólido: roza el 80% de exactitud, con un Kappa cerca de 0.68. Está por debajo del árbol.

4. Naive Bayes

- **Accuracy 0.5986, Kappa 0.4386, F1 0.597**
- Menor exactitud y Kappa del grupo. Indica confusiones notables, especialmente en clases intermedias.

¿Cuál Es Mejor para Predecir?

- **Random Forest** aparece como el ganador, sin embargo es posible que el modelo tenga un fuerte sobreajuste.
- El **árbol de decisión** base o con CV (82.3% Accuracy) se ubica en segundo lugar, con un Kappa notable (0.71).
- **kNN** (80.4% Accuracy) se ubica cerca del árbol, pero un poco por debajo.
- **Naive Bayes** es el de **menor** exactitud (60%) y tiende a confundir más las categorías.

La elección radica entre Knn, arboles de desición y random forest , siendo este ultimo el mejor para predecir en la práctica. Por lo que elegir KNN no es una mala opción.

3. ¿Cuál Se Demoró Más en Procesar?

- En este caso el modelo con más tiempo de procesamiento fue KNN debido a que en etapas de prueba knn es más lento, específicamente si el conjunto de datos es considerablemente grande lo cual es el caso, por lo que el cálculo de distancias es mayor.