

Entrega 5 - Regresion Logistica

Rodrigo Mansilla, Javier Chen

2025-02-25

##Creación de las variables dicotomicas

Table 1: Distribución de PriceCat en train_data

Var1	Freq
Economicas	256
Intermedias	509
Caras	259

Table 2: Distribución de Es_Economica en train_data

Var1	Freq
0	768
1	256

Table 3: Distribución de Es_Intermedia en train_data

Var1	Freq
0	515
1	509

Table 4: Distribución de Es_Cara en train_data

Var1	Freq
0	765
1	259

Se crearon tres variables dicotómicas que indican la pertenencia o no a cada categoría:

Es_Económica (1 si la vivienda es económica, 0 si no lo es)

Es_Intermedia (1 si la vivienda es intermedia, 0 si no lo es)

Es_Cara (1 si la vivienda es cara, 0 si no lo es) ## Modelo de regresión logística El modelo propuesto incluye como predictores a las variables:

OverallQual (calidad global de la vivienda)

GrLivArea (superficie habitable sobre rasante)

YearBuilt (año de construcción de la vivienda)

Table 5: Resumen del Modelo Logístico

Line
Call: NULL
Coefficients: Estimate Std. Error z value Pr(> z) (Intercept) -3.3155 0.2530 -13.107 < 2e-16 *** OverallQual 2.1529 0.2355 9.142 < 2e-16 *** GrLivArea 2.4332 0.2410 10.097 < 2e-16 *** YearBuilt 0.6520 0.1567 4.161 3.17e-05 ***
— Signif. codes: 0 ‘ ’ 0.001 ’ ’ 0.01 ’ ’ 0.05 ‘ ’ 0.1 ’ ’ 1
(Dispersion parameter for binomial family taken to be 1)
Null deviance: 1158.21 on 1023 degrees of freedom Residual deviance: 436.63 on 1020 degrees of freedom AIC: 444.63
Number of Fisher Scoring iterations: 7

Se observa el resumen de la regresión logística:

- Intercept = -3.3155 ($p < 2e-16$)
- OverallQual = 2.1529 ($p < 2e-16$)
- GrLivArea = 2.4332 ($p < 2e-16$)
- YearBuilt = 0.6520 ($p = 3.17e-05$)

Todas las variables son estadísticamente significativas al nivel de $p < 0.001$, lo que indica que tienen un efecto importante en la probabilidad de que una vivienda sea clasificada como “cara”, la probabilidad de ser “cara” es muy baja.

- Null deviance: 1158.21
- Residual deviance: 436.63
- AIC: 444.63

La gran reducción de la deviance indica que el modelo está ajustando notablemente mejor que un modelo nulo sin predictores.

Interpretación de los coeficientes

- OverallQual: Incrementar en 1 unidad esta variable multiplica las probabilidades de que una vivienda sea cara por $\exp(2.1529)$.
- GrLivArea: Cada unidad adicional de GrLivArea aumenta las probabilidades de ser cara por $\exp(2.4332)$.
- YearBuilt: Cada año adicional de antigüedad (más reciente) se asocia con un factor multiplicativo de $\exp(0.6520)$ en las probabilidades de ser cara.

Es importante revisar la escala real de cada predictor para interpretar correctamente el impacto absoluto. Sin embargo, el alto nivel de significancia de las variables confirma que las tres capturan factores relevantes para predecir si la vivienda se encuentra en la categoría de “caras”.

Predicción y evaluación del modelo

Table 6: Matriz de Confusión en Entrenamiento

Predicted	Actual	Freq
0	0	727
1	0	38
0	1	56
1	1	203

Table 7: Precisión del Modelo en Entrenamiento

Metrica	Valor
Precisión	0.9082031

Table 8: Sensibilidad del Modelo en Entrenamiento

Metrica	Valor
Sensibilidad	0.8423237

Table 9: Especificidad del Modelo en Entrenamiento

Metrica	Valor
Especificidad	0.9284802

Multicolinealidad

Table 10: Valores de VIF para el Modelo Logístico

Variable	VIF
OverallQual	1.183839
GrLivArea	1.274443
YearBuilt	1.380776


Variable	VIF
----------	-----

Un VIF inferior a 5 (incluso algunos autores toman 10) sugiere **ausencia de multicolinealidad severa**. En este caso, los valores están muy por debajo de 5, lo que indica que **no** hay problemas graves de multicolinealidad en las variables predictoras.

Matriz de correlación

Table 11: Matriz de Correlación de Predictores

	OverallQual	GrLivArea	YearBuilt
OverallQual	1.0000000	0.6185641	0.5527962
GrLivArea	0.6185641	1.0000000	0.2225015
YearBuilt	0.5527962	0.2225015	1.0000000



Si bien las correlaciones entre **OverallQual** y **GrLivArea** (0.62) y entre **OverallQual** y **YearBuilt** (0.55) son moderadas, no son lo suficientemente altas como para suponer un problema de colinealidad. Esto coincide con los bajos valores de VIF.

Predicción en el conjunto de prueba

Table 12: Matriz de Confusión en el Conjunto de Prueba


Predicted	Actual	Freq
0	0	306
1	0	22
0	1	23
1	1	85

Table 13: Métricas Globales del Modelo en el Conjunto de Prueba

Accuracy	Kappa	AccuracyLower	AccuracyUpper	AccuracyNull	AccuracyPValue	McnemarPValue
0.896789	0.7222065	0.8643385	0.9237163	0.7522936	0	1

Una exactitud de casi 90% en el conjunto de prueba indica que el modelo conserva un buen desempeño fuera de la muestra de entrenamiento. Además, el valor de **Kappa** de alrededor de 0.72 sugiere un acuerdo sustancial entre las predicciones y la realidad.

Curvas de Aprendizaje



Para determinar si existe sobreajuste, se comparan los resultados en entrenamiento y en prueba:

- **Entrenamiento**
- Precisión: 0.9082 (90.82%)
- **Prueba**
- Precisión: 0.8968 (89.68%)
-

La diferencia entre 90.82% (entrenamiento) y 89.68% (prueba) es relativamente pequeña (1.14 puntos porcentuales). Esto sugiere que **no hay un sobreajuste considerable**, pues el modelo rinde de manera bastante uniforme tanto en el conjunto de entrenamiento como en el de prueba.

El gráfico de las curvas de aprendizaje muestra la evolución del error de entrenamiento y de prueba a medida que aumenta el tamaño de los datos utilizados. Se observa que:

- Ambos errores (train y test) convergen a valores cercanos (0.08–0.09).
- No hay una gran brecha entre el error de entrenamiento y el error de prueba; esto confirma visualmente la **ausencia de sobreajuste** y la buena capacidad de generalización del modelo.