

Entrega 3- Naive Bayes

Rodrigo Mansilla, Javier Chen

2025-02-25

Metodología

Se cargan los datos, se limpian y se dividen en train y test. Luego se entrena un modelo de Naive Bayes y se evalúa su desempeño.

Table 1: Dimensiones originales (ANTES del preprocesamiento)

Dataset	Filas	Columnas
Train	1169	84
Test	291	84

Table 2: Dimensiones después del preprocesamiento (Eliminación de NA y ajuste de niveles)

Dataset	Filas	Columnas
Train	1098	84
Test	267	84

```
## character(0)
```

Entrenamiento del modelo

Se entrena un modelo de regresión usando Naive Bayes. Establecemos una cantidad de 50 bins para la variable objetivo "SalePrice" y se ajusta el modelo.

Se realiza el cálculo de los centroides de cada bin y se ajusta el modelo de Naive Bayes.

Table 3: Centros de cada bin (limitado a 10) - Naive Bayes

Centro_Bin
10.89284
11.36236
11.46927
11.55861
11.59895
11.63479
11.67568

11.70498
11.72800
11.74793

Predicciones y Evaluación

Se entrena el modelo de Naive Bayes y se evalúa su desempeño.

Table 4: Métricas de Evaluación del Modelo Naive Bayes (Regresión)


Métrica	Valor
RMSE	0.2316
MAE	0.1644
MAPE (%)	1.3700
R-squared	0.6953

Dentro de los primeros hallazgos del modelo segun las metricas se destaca lo siguiente:

- **RMSE:** La desviacion entre los valores reales sugiere que las predicciones son bastante acertadas.
- **MAE:** Indica un rendimiento bueno y que hay errores absolutos bajos.
- **MAPE:** El error es positivo, indicando que las predicciones estan cerca de los valores reales.
- **R-SQUARED:** Las predicciones presentan una variabilidad aceptable.

Gráfico de predicciones

Se grafican las predicciones del modelo de Naive Bayes.



- La distribución de las predicciones se encuentra alrededor de la línea de tendencia, confirmando que el modelo capta la relación entre la variable objetivo y las predicciones.

En conjunto, el modelo presenta errores moderados, indicando predicciones consistentes. A pesar de dejar una porción de la varianza sin explicar, el modelo ofrece un desempeño aceptable y un buen ajuste a los datos.

Comparación con Modelos Anteriores

Modelo de Regresión Lineal

Se entrena un modelo de regresión lineal stepwise y se evalúa su desempeño.

Table 5: RMSE del Modelo de Regresión Lineal (Stepwise)

Modelo	RMSE
Regresión Lineal (Stepwise)	0.134

Modelo de Árbol de Regresión

Árbol de Regresión: Modelo Base




Table 6: RMSE del Árbol de Regresión (Modelo Base)

Modelo	RMSE
Árbol de Regresión (Modelo Base)	0.2003

Modelo de Random Forest

Table 7: RMSE del Random Forest

Modelo	RMSE
Random Forest	0.1459

Comparación de Modelos

Para comparar los modelos , se presentan las métricas de evaluación de cada uno de ellos y los gráficos de dispersión de las predicciones.

Métricas de Evaluación

Table 8: Comparación Final de Métricas


Modelo	RMSE	MAE	MAPE	R2
Naive Bayes	0.2316353	0.1644440	1.3673777	0.5947377
Regresión Lineal (Stepwise)	0.1339698	0.0844040	0.7008051	0.8644372
Árbol de Regresión	0.2002963	0.1527056	1.2631611	0.6969792
Random Forest	0.1458543	0.1017661	0.8416081	0.8393189

Las métricas presentan los siguientes resultados:


- **Regresión Lineal (Stepwise)** logra el menor RMSE y la menor MAPE, además del R^2 más alto. Esto sugiere que el modelo captura de forma muy precisa las variaciones de precio, con errores bajos tanto absolutos como relativos.
- **Random Forest** se ubica segundo en desempeño. Aunque no alcanza la precisión de la regresión lineal stepwise, ofrece un resultado sólido e incorpora no linealidades de forma más robusta que un modelo lineal puro.
- **Árbol de Regresión (modelo base)** queda por detrás en términos de RMSE y R^2 . Al ser un árbol único, presenta más sesgo y fragmenta el espacio de predicción de forma más burda; de ahí los escalones en la gráfica de “Predicción vs. Valor Real”.
- **Naive Bayes (Regresión)** es el que muestra **mayor error** y menor R^2 . Esto concuerda con la naturaleza del método, que en su versión “regresión” requiere binning de la variable objetivo y puede perder detalle al modelar precios.

Gráficos de Predicciones

Predicción vs. Valor Real por Modelo



Comparación de Predicción vs. Valor Real: NB, Lineal, Árbol y RF



Árbol de Regresión

- Se ven “niveles” horizontales claras, reflejo de la naturaleza escalonada de las reglas de partición de un solo árbol.
- Existe mayor dispersión lejos de la diagonal en ciertos rangos, mostrando que el modelo puede subestimar o sobreestimar el valor real.

Naive Bayes

- Los puntos tienden a formar nubes dispersas, con varios valores concentrados por debajo de 11.5 y por encima de 12.5 que se alejan de la diagonal.
- Esto coincide con un error porcentual más alto (MAPE=1.367%), indicando que para valores “extremos” el modelo falla más.

Random Forest

- La nube de puntos está más concentrada alrededor de la diagonal. Se observa que el modelo capta bastante bien la tendencia, si bien aún hay cierta dispersión para precios muy altos.
- El RMSE cercano a 0.146 es bastante bueno, sugiriendo un balance entre sesgo y varianza mejor que el árbol único.

Regresión Lineal (Stepwise)

- Visualmente, es el que muestra mayor alineación con la línea roja. La mayoría de puntos se concentran muy cerca de la diagonal, confirmando su RMSE y MAPE más bajos.
 - El R^2 elevado (0.8644) indica que el modelo logra explicar más del 86% de la variabilidad de los precios.
1. **El precio de la vivienda parece tener relaciones bastante lineales con varias variables** (por ejemplo, área total, área habitable, características de calidad como “OverallQual”, etc.). Esto favorece a la regresión lineal stepwise, que captura con precisión dichas relaciones.
 2. **Los modelos de árbol** ofrecen la posibilidad de capturar interacciones y no linealidades. En este caso:
 - El **árbol único** no logra la complejidad necesaria para capturar la diversidad de factores que influyen en el precio .
 - El **random forest**, en cambio, reduce la varianza combinando múltiples árboles; por eso su desempeño es notable .
 3. **Naive Bayes** parte de supuestos de independencia condicional y de discretización , por lo que no resulta ideal para pronosticar precios continuos y con muchas interacciones. Los resultados confirman que es el más débil de los cuatro.

Entrenamiento de un Modelo de Naive Bayes de clasificación

Se entrena el modelo con la variable PriceCat creada previamente la cual comprende una clasificación de los precios de las casas en 5 las siguientes categorías: A partir de la variable SalePrice, podemos proponer:

- **Económicas:** casas con SalePrice < 130,000 (aprox. primer cuartil)
- **Intermedias:** casas con SalePrice >= 130,000 y < 215,000 (entre el primer y el tercer cuartil)
- **Caras:** casas con SalePrice >= 215,000 (por encima del tercer cuartil)

Table 9: Resumen de SalePrice en train

Estadística	Valor
Min.	10.47195

1st Qu.	11.80904
Median	12.02647
Mean	12.05032
3rd Qu.	12.29739
Max.	13.00035

Se calculan los cuantiles para definir los límites de las categorías.

Table 10: Umbrales elegidos para clasificar

Categoría	Descripción
Económicas	< 11.8090406157788
Intermedias	$[11.8090406157788 , 12.2973932190659)$
Caras	≥ 12.2973932190659

Se crea la variable PriceCat en el conjunto de entrenamiento y se ajusta el modelo de Naive Bayes.

Table 11: Distribución de PriceCat en train

PriceCat	Frecuencia
Economicas	275
Intermedias	548
Caras	275

Table 12: Distribución de PriceCat en test

PriceCat	Frecuencia
Economicas	71
Intermedias	131
Caras	65

Finalmente, se entrena el modelo de Naive Bayes

Table 13: Matriz de Confusión del Modelo Naive Bayes (Clasificación)

Referencia	Predicción	Frecuencia
Economicas	Economicas	69
Intermedias	Economicas	2
Caras	Economicas	0
Economicas	Intermedias	40
Intermedias	Intermedias	47
Caras	Intermedias	44
Economicas	Caras	1
Intermedias	Caras	12
Caras	Caras	52

Table 14: Métricas Globales del Modelo Naive Bayes (Clasificación)

Métrica	Accuracy	Kappa	AccuracyLower	AccuracyUpper	AccuracyNull	AccuracyPValue	McNemarPValue
1	0.6292135	0.4632675	0.5682245	0.687299	0.4906367	3.6e-06	0

Métricas por clase

Table 15: Métricas por Clase - Parte 1

	Métrica	Sensitivity	Specificity	Pos Pred Value	Neg Pred Value
Class: Economicas	Class: Economicas	0.9718310	0.7908163	0.6272727	0.9872611
Class: Intermedias	Class: Intermedias	0.3587786	0.8970588	0.7704918	0.5922330
Class: Caras	Class: Caras	0.8000000	0.7821782	0.5416667	0.9239766

Table 16: Métricas por Clase - Parte 2

	Métrica	Precision	Recall	F1
Class: Economicas	Class: Economicas	0.6272727	0.9718310	0.7624309
Class: Intermedias	Class: Intermedias	0.7704918	0.3587786	0.4895833
Class: Caras	Class: Caras	0.5416667	0.8000000	0.6459627

Métricas de Evaluación Entrenamiento

Se evalúa en el conjunto de entrenamiento el modelo de Naive Bayes de clasificación.

Table 17: Matriz de Confusión del Modelo Naive Bayes (Entrenamiento)

Referencia	Predicción	Frecuencia
Economicas	Economicas	260
Intermedias	Economicas	15
Caras	Economicas	0
Economicas	Intermedias	168
Intermedias	Intermedias	228
Caras	Intermedias	152
Economicas	Caras	7
Intermedias	Caras	18
Caras	Caras	250

Métricas por clase

Table 18: Métricas Globales del Modelo Naive Bayes (Entrenamiento)

Métrica	Accuracy	Kappa	AccuracyLower	AccuracyUpper	AccuracyNull	AccuracyPValue	McNemarPValue
1	0.6721311	0.5251327	0.6434758	0.6998607	0.4990893	0	0

Table 19: Métricas por Clase (Parte 1) - Entrenamiento

	Métrica	Sensitivity	Specificity	Pos Pred Value	Neg Pred Value
--	---------	-------------	-------------	----------------	----------------

Class: Economicas	Class: Economicas	0.9454545	0.7873633	0.5977011	0.9773756
Class: Intermedias	Class: Intermedias	0.4160584	0.9400000	0.8735632	0.6176822
Class: Caras	Class: Caras	0.9090909	0.8153098	0.6218905	0.9640805

Table 20: Métricas por Clase (Parte 2) - Entrenamiento

	Métrica	Precision	Recall	F1	Balanced Accuracy
Class: Economicas	Class: Economicas	0.5977011	0.9454545	0.7323944	0.8664089
Class: Intermedias	Class: Intermedias	0.8735632	0.4160584	0.5636588	0.6780292
Class: Caras	Class: Caras	0.6218905	0.9090909	0.7385524	0.8622004

Métricas de Evaluación Prueba

Luego se evalúa el modelo de Naive Bayes de clasificación en el conjunto de prueba.

Table 21: Matriz de Confusión del Modelo Naive Bayes (Prueba)

Referencia	Predicción	Frecuencia
Economicas	Economicas	69
Intermedias	Economicas	2
Caras	Economicas	0
Economicas	Intermedias	40
Intermedias	Intermedias	47
Caras	Intermedias	44
Economicas	Caras	1
Intermedias	Caras	12
Caras	Caras	52

Métricas por clase

Table 22: Métricas Globales del Modelo Naive Bayes (Prueba)

Métrica	Accuracy	Kappa	AccuracyLower	AccuracyUpper	AccuracyNull	AccuracyPValue	McnemarPValue
1	0.6292135	0.4632675	0.5682245	0.687299	0.4906367	3.6e-06	0

Table 23: Métricas por Clase (Parte 1) - Prueba

	Métrica	Sensitivity	Specificity	Pos Pred Value	Neg Pred Value
Class: Economicas	Class: Economicas	0.9718310	0.7908163	0.6272727	0.9872611
Class: Intermedias	Class: Intermedias	0.3587786	0.8970588	0.7704918	0.5922330
Class: Caras	Class: Caras	0.8000000	0.7821782	0.5416667	0.9239766

Table 24: Métricas por Clase (Parte 2) - Prueba

	Métrica	Precision	Recall	F1	Balanced Accuracy
Class: Economicas	Class: Economicas	0.6272727	0.9718310	0.7624309	0.8813237
Class: Intermedias	Class: Intermedias	0.7704918	0.3587786	0.4895833	0.6279187
Class: Caras	Class: Caras	0.5416667	0.8000000	0.6459627	0.7910891

Desempeño Global del Modelo

2.1 En Entrenamiento

Accuracy ~ 0.672 y Kappa ~ 0.525:

El accuracy indica que, en promedio, un 67.2% de las observaciones del conjunto de entrenamiento se clasifican correctamente. El valor de Kappa de ~0.525 sugiere un acuerdo moderado entre las predicciones y las clases reales, por encima de lo que se esperaría al azar, pero aún no muy alto.

La Matriz de Confusión en entrenamiento muestra que:

- “Económicas” y “Caras” tienen sensibilidades altas, es decir, el modelo identifica correctamente a la mayoría de las viviendas muy baratas o muy caras.
- “Intermedias” presenta la sensibilidad más baja, lo que indica confusión al clasificar casas con un precio medio, posiblemente debido a que muchos atributos se solapan con las otras dos categorías.

2.2 En Prueba

Accuracy ~ 0.629 y Kappa ~ 0.463:

Como suele ocurrir, el desempeño baja un poco fuera de la muestra de entrenamiento, quedando en un ~62.9% de acierto y un acuerdo moderado de 0.46. La pequeña reducción respecto a entrenamiento sugiere cierta pérdida de generalización, aunque no es drástica.

La Matriz de Confusión (Tabla 21) confirma esta tendencia:

- Las casas marcadas realmente como “Económicas” se aciertan la gran mayoría de las veces como “Económicas”, mostrando una sensibilidad muy alta (0.9718).
- Las casas “Caras” se clasifican como “Caras” 52 veces, lo que también da una sensibilidad notable.
- Las “Intermedias” siguen siendo el principal foco de confusión, pues 40 se predicen como “Económicas” y 44 como “Intermedias”, pero otras 47 que eran realmente Intermedias se equivocan en otras categorías o viceversa.

3. Métricas por Clase en Prueba

Económicas

- **Sensibilidad** : casi todas las casas económicas se detectan correctamente.
- **Especificidad**: el modelo descarta razonablemente bien las no “Económicas”.
- **Precisión** : de todas las predichas como “Económicas”, solo ~63% son efectivamente económicas. Esto se explica porque parte de las “Intermedias” tienden a clasificarse como “Económicas”.
- **F1=0.7624**: se ubica en un punto intermedio, reflejando alto recall y moderada precisión.

Intermedias

- **Sensibilidad**: solo un 35.9% de las casas realmente Intermedias se catalogan así, evidenciando la principal debilidad del modelo; parece confundir las intermedias con “Económicas” o “Caras”.
- **Especificidad**: cuando una casa no es Intermedia, el modelo lo suele reconocer bien.
- **Precisión**: de las que se predicen Intermedias, un 77% sí lo son; sin embargo, el bajo recall reduce la efectividad global para esa clase.
- **F1**: es la categoría con F1 más baja, derivado de un balance deficiente entre precisión y recall.

Caras

- **Sensibilidad** : el modelo identifica el 80% de las casas caras correctamente.
- **Precisión**: de las viviendas que se predicen “Caras”, solo el 54% en realidad lo son.
- **F1=0.6460**: un valor moderado que expresa la tensión entre un buen recall y una precisión mejorable.

4. Interpretación de los Resultados

- El alto acierto en “Económicas” se explica porque tienen atributos muy definidos como menor área, menor calidad global, que las distinguen de los otros segmentos.
- Las “Caras” también muestran una aceptable identificabilidad, seguramente relacionadas con características premium como número de autos en garaje, acabados, calidades.
- El punto débil del modelo son las “Intermedias”, pues sus atributos se solapan en parte con las categorías adyacentes, haciendo difícil para Naive Bayes separar claramente si un valor medio se parece más a uno bajo o alto.


Además, el modelo presenta un sesgo al sobrediagnosticar “Económicas” o “Caras” cuando en realidad son “Intermedias”, reflejado en la sensibilidad particularmente baja de la clase Intermedia.

Comparación de Accuracy

Table 25: Comparación de Accuracy en Entrenamiento y Prueba

Dataset	Accuracy
Entrenamiento	0.6721
Prueba	0.6292

Gráfico de Accuracy



Basándonos en la comparación de accuracy entre entrenamiento (0.6721) y prueba (0.6292), no se observa un salto drástico que sugiera un sobreajuste extremo. Un modelo sobreajustado suele presentar un desempeño claramente superior en entrenamiento respecto al conjunto de prueba (a veces, diferencias de 10%–20% o más en la métrica).

En este caso, la reducción de la accuracy de ~ 0.67 en entrenamiento a ~ 0.63 en prueba indica que el modelo sí se ajusta ligeramente mejor a los datos de entrenamiento lo cual es normal, pero esa brecha de menos de 5 puntos porcentuales es moderada y esperable en escenarios reales. Por tanto:

- Hay un mínimo indicio de sobreajuste, pero no es pronunciado.
- El modelo retiene razonablemente su capacidad de generalización al pasar del conjunto de entrenamiento al de prueba.

Modelo de Clasificación con Validación Cruzada

Modelo sin Validación Cruzada

Table 26: RMSE del Modelo Naive Bayes sin Validación Cruzada

RMSE
0.2316353

Modelo con Validación Cruzada

Modelo sin Validación Cruzada

Table 27: RMSE del Modelo Naive Bayes sin Validación Cruzada

Metodo	RMSE
Sin CV	0.6245234

Modelo con Validación Cruzada

Table 28: RMSE del Modelo Naive Bayes con Validación Cruzada

Metodo	RMSE
Con CV	0.6231303

Al utilizar validación cruzada para entrenar el modelo, el RMSE con validación cruzada fue 0.6231303, mientras que el RMSE sin validación cruzada fue 0.6245234. Aunque la diferencia en el RMSE es pequeña, el modelo con validación cruzada funcionó mejor, ya que obtuvo un RMSE más bajo. Además, la validación cruzada proporciona una evaluación más robusta y generalizable del modelo, ayudando a evitar el sobreajuste al evaluar el modelo en múltiples particiones del conjunto de datos.

Busqueda de Hiperparámetros

Table 29: Búsqueda de Hiperparámetros para Naive Bayes

laplace	usekernel	adjust	RMSE
0	TRUE	0.5	0.6231303
1	TRUE	0.5	0.6231303
2	TRUE	0.5	0.6231303
0	FALSE	0.5	0.7472468
1	FALSE	0.5	0.7472468
2	FALSE	0.5	0.7472468
0	TRUE	1.0	0.6305801
1	TRUE	1.0	0.6305801
2	TRUE	1.0	0.6305801
0	FALSE	1.0	0.7472468
1	FALSE	1.0	0.7472468
2	FALSE	1.0	0.7472468
0	TRUE	2.0	0.6623692
1	TRUE	2.0	0.6623692
2	TRUE	2.0	0.6623692
0	FALSE	2.0	0.7472468
1	FALSE	2.0	0.7472468
2	FALSE	2.0	0.7472468

De la búsqueda de parámetros se determina lo siguiente:

1. Se observa que el modelo mejora en términos de RMSE al aplicar la validación cruzada y al afinar parámetros, lo cual implica una mayor confiabilidad de la clasificación.
2. El mejor set de hiperparámetros es:
 - `usekernel` = `TRUE` (estimación no paramétrica),
 - `adjust` = `0.5` (ancho de banda más reducido),
 - `laplace` puede ser cualquiera de `[0, 1, 2]` sin afectar significativamente el RMSE.
3. La reducción de RMSE sugiere que las probabilidades estimadas se ajustan mejor a las verdaderas etiquetas.
4. La menor diferencia en RMSEes indicativa de que la CV reduce sobreajuste y encuentra un modelo más estable.

Por lo tanto, la búsqueda de hiperparámetros para Naive Bayes con validación cruzada sí trajo una ligera mejora y confirmó que `usekernel=TRUE` y `adjust=0.5` ofrecen la mejor configuración para clasificar.

Naive Bayes vs Arboles y Random Forest

Previamente se realizaron modelos de clasificación con arboles de decisión y random forest, a continuación se comparan los resultados obtenidos con el modelo de Naive Bayes y se determina cual de los modelos predice mejor en términos de desempeño y tiempo de predicción.

- **Naive Bayes:** Se observó un accuracy cercano a 0.63 en prueba y una Kappa alrededor de 0.46. Presentó un buen reconocimiento de los extremos (casas muy económicas o muy caras), pero su debilidad fue la clase “Intermedias”, con mucha confusión. El modelo fue el más rápido en predecir dado a que el modelo es sencillo por naturaleza.

- **Árbol de Clasificación:** Alcanzó aproximadamente un accuracy de 0.72 y una Kappa de ~ 0.54 . En general, mejora al Naive Bayes, sobre todo para la clase “Intermedias”; aun así, no es perfecto y suele tener puntos ciegos en los límites entre categorías. Al ser el conjunto de datos de un tamaño considerable, la predicción de este fue mayor a Naive Bayes, sin embargo es relativamente ligero en terminos de computo.
- **Random Forest de Clasificación:** Supera a un solo árbol gracias a la combinación de múltiples árboles . El modelo usa un numero de 500 arboles, por lo cual es el más lento de los tres dado a la evaluación de particiones y submuestras de la variable.

Conclusión de desempeño: El Random Forest suele ser el ganador en términos de exactitud y robustez. El Árbol de Clasificación se ubica en un nivel intermedio. Naive Bayes es el menos preciso de los tres para este problema, aunque muy rápido y sencillo de interpretar en su estructura probabilística.

Si la prioridad es la exactitud en la clasificación, sobre todo para precios de casas que presenten alta variabilidad y características no lineales, el Random Forest habitualmente da los mejores resultados. Si se requiere un modelo sencillo, rápido y con interpretaciones probabilísticas básicas, Naive Bayes es la alternativa más simple. El Árbol de Clasificación ofrece un equilibrio razonable entre interpretabilidad y desempeño, no llega a la precisión del Random Forest. Por lo que la decisión recae entre Modelos predictivos de Naive Bayes y Random Forest, cuya combinación ofrece una predicción sobre las clases bastante acertada.